인공지능 모델 운영 과제 보고서

주제: Cross Validation & Hyperparameter Tuning (Optuna 활용)

이름 : Solihah Salsabila | 학번 : 2555047

1. 전처리 및 방법론 (Methodology)

모델 학습 전 데이터 정제 및 파이프라인 구성을 수행했습니다:

- 데이터 정제: 이름에서 호칭을 추출하여 범주형으로 매핑하고, 불필요한 고유 식별자(`PassengerId`, `Ticket`, `Cabin`, `Name`)를 제거했습니다.
- 결측치 처리: `GroupMedianImputer`를 구현하여 승객 등급과 호칭 그룹별 중앙값을 기준으로 연령 결측치를 대체하여 데이터 누수를 차단했습니다.
- 스케일링 및 인코딩: 수치형 변수는 `StandardScaler`, 범주형 변수는 `OneHotEncoder`를 적용했습니다.

2. Baseline 5-Fold 성능 평가

하이퍼파라미터 튜닝 전, 기본 설정값으로 수행한 Stratified 5-Fold 교차 검증 결과는 다음과 같습니다.

Model	FN+FP	FPR	Recall	Precision	F1-Score	PR_AUC	AUROC
KNN	32.2	0.1294	0.7368	0.7829	0.7581	0.7753	0.8538
Logistic Regression	31.2	0.1202	0.7366	0.7934	0.7631	0.8489	0.8702
Naive Bayes	38.6	0.1585	0.6898	0.7309	0.7087	0.7654	0.8376
Decision Tree	36.6	0.1621	0.7251	0.7358	0.7303	0.6388	0.7788
Random Forest	32.4	0.1311	0.7368	0.7785	0.7568	0.8237	0.8708
XGBoost	32.0	0.1293	0.7396	0.7808	0.7596	0.8495	0.8738

3. Optuna 하이퍼파라미터 튜닝 결과

각 모델별로 50회(Trials)의 Optuna 탐색(TYPES Sampler 기준)을 수행하여 최적의 파라미터를 도출했습니다.

```
[최적 파라미터 도출 요약]

• XGBoost: n_estimators=100, max_depth=8, learning_rate=0.0649, subsample=0.8226

• Random Forest: n_estimators=300, max_depth=15, min_samples_split=2, max_features='log2'

• Logistic Regression: C=6.8468, penalty='12'

• Decision Tree: criterion='gini', max_depth=3, min_samples_split=15

• KNN: n_neighbors=17, weights='uniform', p=1

• Naive Bayes: var_smoothing=1.767e-09
```

4. Tuned 5-Fold 최종 성능 평가

Optuna로 최적화된 하이퍼파라미터를 적용하여 재평가한 결과, 모든 모델에서 성능 향상이 확인되었습니다.

Model	FN+FP	FPR	Recall	Precision	F1-Score	PR_AUC	AUROC
KNN	30.6	0.1129	0.7338	0.8021	0.7662	0.8413	0.8751
Logistic Regression	29.6	0.1166	0.7542	0.8015	0.7767	0.8549	0.8731
Naive Bayes	38.6	0.1585	0.6898	0.7309	0.7087	0.7654	0.8376
Decision Tree	30.4	0.1221	0.7512	0.7935	0.7710	0.8102	0.8629
Random Forest	28.0	0.0984	0.7485	0.8273	0.7853	0.8560	0.8787
XGBoost	26.8	0.0965	0.7631	0.8317	0.7957	0.8619	0.8812

5. 결론 및 고찰

- 성능 향상**:** Optuna를 통한 하이퍼파라미터 튜닝 결과, Baseline 대비 모든 앙상블 및 선형 모델들의 F1-Score와 AUROC 지표가 개선되었습니다.
- 최우수 모델**:** **XGBoost (Tuned)** 모델이 F1-Score 0.7957, AUROC 0.8812, 오분류 수 26.8개로 가장 뛰어난 예측 성능을 기록했습니다.
- 시사점**:** 체계적인 전처리 파이프라인과 Optuna 기반의 자동화된 탐색이 모델의 일반화 성능 향상에 크게 기여함을 확인했습니다.